

《视觉SLAM十四讲》笔记摘抄

《视觉SLAM十四讲》笔记摘抄

ch02 初识SLAM

经典视觉SLAM框架

SLAM问题的数学表述

ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

坐标系间的欧氏变换

变换矩阵与齐次坐标

齐次坐标(Homogeneous Coordinate)的优势

优势1:方便判断是否在直线或平面上

优势2:方便表示线线交点和点点共线

优势3:能够区分向量和点

优势4:能够表达无穷远点

优势5:能够简洁的表示变换

旋转向量和欧拉角

旋转向量

欧拉角

四元数

四元数的定义

用单位四元数表示旋转

ch04 李群与李代数

李群与李代数基础

群的定义

李代数的定义

李代数 $\mathfrak{so}(3)$

李代数 $\mathfrak{se}(3)$

李群与李代数的转换关系:指数映射和对数映射

$SO(3)$ 和 $\mathfrak{so}(3)$ 间的转换关系

$SE(3)$ 和 $\mathfrak{se}(3)$ 间的转换关系

李代数求导: 引入李代数的一大动机就是方便求导优化

李群乘法与李代数加法的关系

$SO(3)$ 上的李代数求导

李代数求导

扰动模型(左乘)

$SE(3)$ 上的李代数求导

ch05 相机与图像

针孔相机模型

畸变模型

单目相机的成像过程

ch06 非线性优化

状态估计问题

最大后验与最大似然

最小二乘

基于观测数据 z 的最小二乘

基于观测数据 z 和输入数据 u 的最小二乘

非线性最小二乘

一阶和二阶梯度法

高斯牛顿法

列文伯格-马夸尔特方法

ch07 视觉里程计01

特征点匹配

特征点

根据特征点匹配计算相机运动

2D-2D匹配: 对极几何

对极约束

本质矩阵 E 的求解

对极几何的讨论

3D-2D匹配: PnP(Perspective-n-Point)

直接线性变换(DLT): 先求解相机位姿,再求解空间点位置

P3P: 先求解空间点位置,再求解相机位姿

Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿


3D-3D匹配: ICP

SVD方法

非线性优化方法

ch02 初识SLAM

经典视觉SLAM框架



视觉SLAM流程包括以下步骤:

1. **传感器信息读取**: 在视觉SLAM中主要为相机图像信息的读取和预处理.如果是在机器人中,还可能有码盘、惯性传感器等信息的读取和同步.

2. **视觉里程计**(Visual Odometry,VO): 视觉里程计的任务是估算相邻图像间相机的运动,以及局部地图的样子.VO又称为前端(Front End).

视觉里程计不可避免会出现**累积漂移**(Accumulating Drift)问题.

3. **后端优化** (Optimization): 后端接受不同时刻视觉里程计测量的相机位姿,以及回环检测的信息,对它们进行优化,得到全局一致的轨迹和地图.由于接在VO之后,又称为后端(Back End).

在视觉 SLAM中,前端和计算机视觉研究领域更为相关,比如图像的特征提取与匹配等,后端则主要是滤波与非线性优化算法.

4. **回环检测** (Loop Closing): 回环检测判断机器人是否到达过先前的位置.如果检测到回环,它会把信息提供给后端进行处理.

5. **建图** (Mapping): 它根据估计的轨迹,建立与任务要求对应的地图.

地图的形式包括**度量地图**(精确表示地图物体的位置关系)与**拓扑地图**(更强调地图元素之间的关系)两种.

SLAM问题的数学表述

“小萝卜携带着传感器在环境中运动”,由如下两件事情描述:

1. 什么是**运动**?我们要考虑从 $k-1$ 时刻到 k 时刻,小萝卜的位置 x 是如何变化的.

运动方程:

$$x_k = f(x_{k-1}, u_k, w_k)$$

1. x_k, x_{k-1} 表示小萝卜在 k 和 $k-1$ 时刻的位置
 2. u_k 表示运动传感器的读数(有时也叫**输入**)
 3. w_k 表示噪声
2. 什么是**观测**?假设小萝卜在 k 时刻于 x_k 处探测到了某一个路标 y_j ,我们要考虑这件事情是如何用数学语言来描述的.

观测方程:

$$z_{k,j} = h(y_j, x_k, v_{k,j})$$

1. $z_{k,j}$ 表示小萝卜在 x_k 位置上看到路标点 y_j 产生的观测数据
2. y_j 表示第 j 个路标点
3. $v_{k,j}$ 表示噪声

这两个方程描述了最基本的SLAM问题:当知道运动测量的读数 u ,以及传感器的读数 z 时,如何求解定位问题(估计 x)和建图问题(估计 y)?这时,我们就把SLAM问题建模成了一个**状态估计问题**:如何通过带有噪声的测量数据,估计内部的、隐藏着的状态变量?

ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

1. 向量 a 在线性空间的基 $[e_1, e_2, e_3]$ 下的坐标为 $[a_1, a_2, a_3]^T$.

$$a = [e_1, e_2, e_3] \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = a_1 e_1 + a_2 e_2 + a_3 e_3$$

2. 向量的内积与外积

1. 向量的内积: 描述向量间的投影关系

$$a \cdot b = a^T b = \sum_{i=1}^3 a_i b_i = |a| |b| \cos \langle a, b \rangle$$

2. 向量的外积: 描述向量的旋转

$$a \times b = \begin{bmatrix} i & j & k \\ a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \end{bmatrix} = \begin{bmatrix} a_2 b_3 - a_3 b_2 \\ a_3 b_1 - a_1 b_3 \\ a_1 b_2 - a_2 b_1 \end{bmatrix} = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix} b \triangleq a^\wedge b$$

其中 a^\wedge 表示 a 的反对称矩阵

$$a^\wedge = \begin{bmatrix} 0 & -a_3 & a_2 \\ a_3 & 0 & -a_1 \\ -a_2 & a_1 & 0 \end{bmatrix}$$

坐标系间的欧氏变换

1. 欧式变换:

在欧式变换前后的两个坐标系下,同一个向量的模长和方向不发生改变,是为欧式变换.

一个欧式变换由一个旋转和一个平移组成.

2. 旋转矩阵 R :

1. 旋转矩阵 R 的推导:

设单位正交基 $[e_1, e_2, e_3]$ 经过一次旋转变成了 $[e'_1, e'_2, e'_3]$,对于同一个向量 a ,在两个坐标系下的坐标分别为 $[a_1, a_2, a_3]^T$ 和 $[a'_1, a'_2, a'_3]^T$.根据坐标的定义:

$$[e_1, e_2, e_3] \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = [e'_1, e'_2, e'_3] \begin{bmatrix} a'_1 \\ a'_2 \\ a'_3 \end{bmatrix}$$

等式左右两边同时左乘 $[e_1^T, e_2^T, e_3^T]^T$,得到

$$\begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} e_1^T e'_1 & e_1^T e'_2 & e_1^T e'_3 \\ e_2^T e'_1 & e_2^T e'_2 & e_2^T e'_3 \\ e_3^T e'_1 & e_3^T e'_2 & e_3^T e'_3 \end{bmatrix} \begin{bmatrix} a'_1 \\ a'_2 \\ a'_3 \end{bmatrix} \triangleq Ra'$$

矩阵 R 描述了旋转,称为**旋转矩阵**.

2. 旋转矩阵 R 的性质

1. 旋转矩阵是**行列式为1的正交矩阵**,任何行列式为1的正交矩阵也是一个旋转矩阵.所有旋转矩阵构成特殊正交群 SO :

$$SO(n) = \{R \in \mathbb{R}^{n \times n} | RR^T = I, \det(R) = 1\}$$

2. 旋转矩阵是正交矩阵(其转置等于其逆),旋转矩阵的逆 R^{-1} (即转置 R^T)描述了一个相反的旋转.

3. 欧式变换的向量表示:

世界坐标系中的向量 a ,经过一次旋转(用旋转矩阵 R 描述)和一次平移(用平移向量 t 描述)后,得到了 a' :

$$a' = Ra + t$$

变换矩阵与齐次坐标

1. 变换矩阵 T :

在三维向量的末尾添加1,构成的四维向量称为**齐次坐标**.将旋转和平移写入**变换矩阵 T** 中,得到:

$$\begin{bmatrix} a' \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ 1 \end{bmatrix} \triangleq T \begin{bmatrix} a \\ 1 \end{bmatrix}$$

齐次坐标的意义在于**将欧式变换表示为线性关系**.

2. 变换矩阵 T 的性质:

1. 变换矩阵 T 构成特殊欧式群 SE

$$SE(3) = \left\{ T = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} | R \in SO(3), t \in \mathbb{R}^3 \right\}$$

2. 变换矩阵的逆表示一个反向的欧式变换

$$T^{-1} = \begin{bmatrix} R^T & -R^T t \\ 0 & 1 \end{bmatrix}$$

齐次坐标(Homogeneous Coordinate)的优势

优势1:方便判断是否在直线或平面上

若点 $p = (x, y)$ 在直线 $l = (a, b, c)$ 上,则有:

$$ax + by + c = [a, b, c]^T \cdot [x, y, 1] = l^T \cdot p' = 0$$


若点 $p = (x, y, z)$ 在平面 $A = (a, b, c, d)$ 上,则有:

$$ax + by + cz + d = [a, b, c, d]^T \cdot [x, y, z, 1] = A^T \cdot p' = 0$$

优势2:方便表示线线交点和点点共线

在齐次坐标下,

- 1. 可以用两个点 p, q 的齐次坐标叉乘结果表示它们的共线 l .
- 2. 可以用两条直线 l, m 的齐次坐标叉乘结果表示它们的交点 x .



这里利用叉乘的性质: 叉乘结果与两个运算向量都垂直:

- 性质1的证明:

$$\begin{aligned} l^T \cdot p &= (p \times q) \cdot p = 0 \\ l^T \cdot q &= (p \times q) \cdot q = 0 \end{aligned}$$

- 性质2的证明:

$$\begin{aligned} l^T \cdot p &= l^T \cdot (l \times m) = 0 \\ m^T \cdot p &= m^T \cdot (l \times m) = 0 \end{aligned}$$

优势3:能够区分向量和点

- 点 (x, y, z) 的齐次坐标为 $(x, y, z, 1)$
- 向量 (x, y, z) 的齐次坐标为 $(x, y, z, 0)$



优势4:能够表达无穷远点

对于平行直线 $l = (a, b, c)$ 和 $m = (a, b, d)$,求取其交点的齐次坐标 $x = l \times m = (kb, -ka, 0)$,将其转为非齐次坐标,得到 $x = (kb/0, -ka/0) = (\inf, -\inf)$,这表示无穷远点.

优势5:能够简洁的表示变换

使用齐次坐标,可以将加法运算转化为乘法运算.

变换形式	图形示意	数学变换	MATLAB函数
位移(Translation)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imtranslate()</code>
缩放(Scale)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imresize()</code>

变换形式	图形示意	数学变换	MATLAB函数
错切(Shear)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & h_x & 0 \\ h_y & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	
旋转(Rotate)		$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta & 0 \\ -\sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$	<code>imrotate()</code>

旋转向量和欧拉角

旋转向量

- 旋转矩阵的缺点:
 - 旋转矩阵有9个量,但一次旋转只有3个自由度,这种表达方式是冗余的.
 - 旋转矩阵自带约束(必须是行列式为1的正交矩阵),这些约束会给估计和优化带来困难.
- 旋转向量: 任意旋转都可以用一个**旋转轴**和一个**旋转角** 来刻画.于是,我们可以使用一个向量,其**方向表示旋转轴**而**长度表示旋转角**.这种向量称为**旋转向量**(或**轴角**,Axis-Angle).

假设有一个旋转轴为 n ,角度为 θ 的旋转,其对应的旋转向量为 θn .

- 旋转向量和旋转矩阵之间的转换:

设旋转向量 R 表示一个绕单位向量 n ,角度为 θ 的旋转.

- 旋转向量到旋转矩阵:

$$R = \cos \theta I + (1 - \cos \theta)nn^T + \sin \theta n^\wedge$$

- 旋转矩阵到旋转向量:

- 旋转角 $\theta = \arccos \left(\frac{tr(R)-1}{2} \right)$
- 旋转轴 n 是矩阵 R 特征值1对应的特征向量

欧拉角

- 欧拉角将一次旋转分解成**3个分离的转角**.常用的一种ZYX转角将任意旋转分解成以下3个轴上的转角:
 - 绕物体的 Z 轴旋转,得到偏航角yaw
 - 绕**旋转之后的** Y 轴旋转,得到俯仰角pitch
 - 绕**旋转之后的** X 轴旋转,得到滚转角roll
- 欧拉角的一个重大缺点是**万向锁问题(奇异性问题)**: 在俯仰角为 $\pm 90^\circ$ 时,第一次旋转与第三次旋转将使用同一个轴,使得系统丢失了一个自由度(由3次旋转变成了2次旋转).

四元数

为什么需要四元数: 对于三维旋转,找不到**不带奇异性的三维向量描述方式**.因此引入四元数.
四元数是一种**扩展的复数**,既是**紧凑的**,也没有**奇异性**.

四元数的定义

- 四元数的定义

一个四元数 q 拥有一个实部和三个虚部

$$q = q_0 + q_1i + q_2j + q_3k$$

其中 i,j,k ,为四元数的3个虚部,它们满足以下关系式(**自己和自己的运算像复数,自己和别人的运算像叉乘**):

$$\begin{cases} i^2 = j^2 = k^2 = -1 \\ ij = k, ji = -k \\ jk = i, kj = -i \\ ki = j, ik = -j \end{cases}$$

也可以用 一个标量和一个向量 来表达四元数:

$$q = [s, v], \quad s = q_0 \in \mathbb{R} \quad v = [q_1, q_2, q_3]^T \in \mathbb{R}^3$$

s 为四元数的实部, v 为四元数的虚部. 有**实四元数**和**虚四元数**的概念.

2. 四元数与旋转角度的关系:

- 在二维情况下, 任意一个旋转都可以用**单位复数**来描述, 乘 i 就是绕 i 轴旋转 90° .
- 在三维情况下, 任意一个旋转都可以用**单位四元数**来描述, 乘 i 就是绕 i 轴旋转 180° .

3. 单位四元数和旋转向量之间的转换:

设单位四元数 q 表示一个绕单位向量 $n = [n_x, n_y, n_z]^T$, 角度为 θ 的旋转.

1. 从旋转向量到单位四元数:

$$q = \left[\cos\left(\frac{\theta}{2}\right), n \sin\left(\frac{\theta}{2}\right) \right]^T = \left[\cos\left(\frac{\theta}{2}\right), n_x \sin\left(\frac{\theta}{2}\right), n_y \sin\left(\frac{\theta}{2}\right), n_z \sin\left(\frac{\theta}{2}\right) \right]^T$$

1. 从单位四元数到旋转向量:

$$\begin{cases} \theta = 2 \arccos q_0 \\ [n_x, n_y, n_z] = [q_1, q_2, q_3]^T / \sin \frac{\theta}{2} \end{cases}$$

用单位四元数表示旋转

给定一个空间三维点 $p = [x, y, z] \in \mathbb{R}^3$, 以及一个由轴角 n, θ 指定的旋转, 三维点 p 经过旋转后变为 p' . 如何使用单位四元数 q 表达旋转?

1. 把三维空间点用一个虚四元数 p 表示:

$$p = [0, x, y, z] = [0, v]$$

2. 把旋转用单位四元数 q 表示:

$$q = [\cos \frac{\theta}{2}, n \sin \frac{\theta}{2}]$$

3. 旋转后的点 p' 可表示为:

$$p' = qpq^{-1}$$

这样得到的点 p' 仍为一个纯虚四元数, 其虚部的 3 个分量表示旋转后 3D 点的坐标.

只有**单位四元数**才能表示旋转, 因此在程序中创建四元数后, 要记得调用 `normalize()` 以将其单位化

ch04 李群与李代数

李群与李代数基础

旋转矩阵构成特殊正交群 $SO(3)$, 变换矩阵构成了特殊欧氏群 $SE(3)$.

$$SO(3) = \{ R \in \mathbb{R}^{3 \times 3} | RR^T = I, \det(R) = 1 \}$$

$$SE(3) = \left\{ T = \begin{bmatrix} R & t \\ 0^T & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 4} | R \in SO(3), t \in \mathbb{R}^3 \right\}$$

群的定义

- 群(Group)是一种集合加上一种运算的代数结构.把集合记作 A ,运算记作 \cdot ,那么群可以记作 $G = (A, \cdot)$.群要求这个运算满足如下条件(封闭么逆):

1. 封闭性: $\forall a_1, a_2 \in A, \quad a_1 \cdot a_2 \in A$.
2. 结合律: $\forall a_1, a_2, a_3 \in A, \quad (a_1 \cdot a_2) \cdot a_3 = a_1 \cdot (a_2 \cdot a_3)$
3. 么元: $\exists a_0 \in A, \quad \text{s.t.} \quad \forall a \in A, \quad a_0 \cdot a = a \cdot a_0 = a$
4. 逆: $\forall a \in A, \quad \exists a^{-1} \in A, \quad \text{s.t.} \quad a \cdot a^{-1} = a_0$

- 李群是指具有连续(光滑)性质的群. $SO(3)$ 和 $SE(3)$ 都是李群

李代数的定义

每个李群都有与之对应的李代数,李代数描述了李群的局部性质.

通用的李代数的定义如下:

李代数由一个集合 V ,一个数域 F 和一个二元运算 $[\cdot, \cdot]$ 组成.如果它们满足以下几条性质,则称 $(V, F, [\cdot, \cdot])$ 为一个李代数.记作 \mathfrak{g} .

1. 封闭性: $\forall X, Y \in V, [X, Y] \in V$.
2. 双线性: $\forall X, Y, Z \in V, a, b \in F$ 有:

$$[aX + bY, Z] = a[X, Z] + b[Y, Z], \quad [Z, aX + bY] = a[Z, X] + b[Z, Y]$$

3. 自反性: $\forall X \in V, [X, X] = 0$.
4. 雅可比等价 $\forall X, Y, Z \in V, [X, [Y, Z]] + [Z, [X, Y]] + [Y, [Z, X]] = 0$.

其中的二元运算 $[\cdot, \cdot]$ 被称为李括号.例如三维向量空间 \mathbb{R}^3 上定义的叉积 \times 是一种李括号.

李代数 $\mathfrak{so}(3)$

- 李群 $SO(3)$ 对应的李代数 $\mathfrak{so}(3)$ 是定义在 \mathbb{R}^3 上的向量,记作 ϕ .

$$\mathfrak{so}(3) = \left\{ \phi \in \mathbb{R}^3, \Phi = \phi^\wedge = \begin{bmatrix} 0 & -\phi_3 & \phi_2 \\ \phi_3 & 0 & -\phi_1 \\ -\phi_2 & \phi_1 & 0 \end{bmatrix} \in \mathbb{R}^{3 \times 3} \right\}$$

- 李代数 $\mathfrak{so}(3)$ 的李括号为

$$[\phi_1, \phi_2] = (\Phi_1 \Phi_2 - \Phi_2 \Phi_1)^\vee$$

其中 $^\vee$ 是 $^\wedge$ 的逆运算,表示将反对称矩阵还原为向量

- $\mathfrak{so}(3)$ 和 $SO(3)$ 间的映射关系为

$$\begin{aligned} \text{李群 } R &= \exp(\phi^\wedge) = \exp(\Phi) \\ \text{李代数 } \phi &= \ln(R)^\vee \end{aligned}$$

李代数 $\mathfrak{se}(3)$

- 类似地,李群 $SE(3)$ 的李代数 $\mathfrak{se}(3)$ 是定义在 \mathbb{R}^6 上的向量,记作 ξ :

$$\mathfrak{se}(3) = \left\{ \xi = \begin{bmatrix} \rho \\ \phi \end{bmatrix} \in \mathbb{R}^6, \rho \in \mathbb{R}^3, \phi \in \mathfrak{so}(3), \xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ 0^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4} \right\}$$

$\mathfrak{se}(3)$ 中的每个元素 ξ ,是一个六维向量.前三维 ρ 表示平移;后三维 ϕ 表示旋转,本质上是 $\mathfrak{so}(3)$ 元素.

- 在这里同样使用 $^\wedge$ 符号将六维向量扩展成为四维矩阵,但不再表示反对称

$$\xi^\wedge = \begin{bmatrix} \phi^\wedge & \rho \\ 0^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4}$$

- 李代数 $\mathfrak{se}(3)$ 的李括号和 $\mathfrak{so}(3)$ 类似:

$$[\xi_1, \xi_2] = (\xi_1^\wedge \xi_2^\wedge - \xi_2^\wedge \xi_1^\wedge)^\vee$$

- $\mathfrak{se}(3)$ 和 $SE(3)$ 间映射关系为

$$\begin{aligned} \text{李群} T &= \exp(\xi^\wedge) \\ \text{李代数} \xi &= \ln(T)^\vee \end{aligned}$$

李群与李代数的转换关系:指数映射和对数映射

$SO(3)$ 和 $\mathfrak{so}(3)$ 间的转换关系

- 将三维向量 ϕ 分解为其模长 θ 和方向向量 α ,即 $\phi = \theta \alpha$.则从 $\mathfrak{so}(3)$ 到 $SO(3)$ 的**指数映射**可表示为:

$$R = \exp(\phi) = \exp(\theta \alpha^\wedge) = \cos \theta I + (1 - \cos \theta) \alpha \alpha^T + \sin \theta \alpha^\wedge$$

上式即为旋转向量到旋转矩阵的罗德里格斯公式,可见** $\mathfrak{so}(3)$ 本质上是旋转向量组成的空间**.

- 从 $SO(3)$ 到 $\mathfrak{so}(3)$ 的**对数映射**可表示为:

$$\phi = \ln(R)^\vee$$

实际计算时可以通过迹的性质分别求出转角 θ 和转轴 α

$$\theta = \arccos \frac{tr(R) - 1}{2}, \quad R \alpha = \alpha$$

$SE(3)$ 和 $\mathfrak{se}(3)$ 间的转换关系

- 从 $\mathfrak{se}(3)$ 到 $SE(3)$ 的**指数映射**可表示为:

$$T = \exp(\xi^\wedge) = \begin{bmatrix} R & J \rho \\ 0^T & 1 \end{bmatrix}$$

其中

$$J = \frac{\sin \theta}{\theta} I + (1 - \frac{\sin \theta}{\theta}) \alpha \alpha^T + \frac{1 - \cos \theta}{\theta} \alpha^\wedge$$


可以看到,平移部分经过指数映射之后,发生了一次以 J 为系数矩阵的线性变换.

- 从 $SE(3)$ 到 $\mathfrak{se}(3)$ 的**对数映射**可表示为:


$$\xi = \ln(T)^\vee$$

实际计算时 ϕ 可以由 $SO(3)$ 到 $\mathfrak{so}(3)$ 的映射得到, ρ 可以由 $t = J \rho$ 计算得到.

三维旋转



三维变换



李代数求导: 引入李代数的一大动机就是方便求导优化

李群乘法与李代数加法的关系

1. BCH公式及其近似形式

1. 很遗憾地,李群乘积和李代数加法并不等价,即:

$$R_1 R_2 = \exp(\phi_1^\wedge) \exp(\phi_2^\wedge) \neq \exp((\phi_1 + \phi_2)^\wedge)$$

李群乘积与李代数运算的对应关系由BCH公式给出:

$$\ln(\exp(A) \exp(B)) = A + B + \frac{1}{2}[A, B] + \frac{1}{12}[A, [A, B]] - \frac{1}{12}[B, [A, B]] + \dots$$

上式中 $[\cdot, \cdot]$ 表示李括号运算.

2. 当 ϕ_1 或 ϕ_2 为小量时,可以对BCH公式进行线性近似,得到李群乘积对应的李代数的表达式:

$$R_1 \cdot R_2 \text{ 对应的李代数} = \ln(\exp(\phi_1^\wedge) \exp(\phi_2^\wedge))^\vee \approx \begin{cases} J_l(\phi_2)^{-1} \phi_1 + \phi_2 & \text{当 } \phi_1 \text{ 为小量时} \\ J_r(\phi_1)^{-1} \phi_2 + \phi_1 & \text{当 } \phi_2 \text{ 为小量时} \end{cases}$$

其中左乘雅可比矩阵 J_l 即为从 $SE(3)$ 到 $\mathfrak{se}(3)$ 对数映射中的雅可比矩阵

$$J_l = \frac{\sin \theta}{\theta} I + \left(1 - \frac{\sin \theta}{\theta}\right) \alpha \alpha^T + \frac{1 - \cos \theta}{\theta} \alpha^\wedge$$

其逆为

$$J_l^{-1} = \frac{\theta}{2} \cot \frac{\theta}{2} I + \left(1 - \frac{\theta}{2} \cot \frac{\theta}{2}\right) \alpha \alpha^T + \frac{\theta}{2} \alpha^\wedge$$

右乘雅可比矩阵只需对自变量取负号即可

$$J_r(\phi) = J_l(-\phi)$$

2. 李群 $SO(3)$ 乘法与李代数 $\mathfrak{so}(3)$ 加法的关系:

1. 对旋转 R (李代数为 ϕ)左乘一个微小旋转 ΔR (李代数为 $\Delta \phi$),得到的旋转李群 $\Delta R \cdot R$ 对应的李代数为:

$$\Delta R \cdot R \text{ 对应的李代数} = \ln(\exp(\Delta \phi^\wedge) \exp(\phi^\wedge)) = \phi + J_l^{-1}(\phi) \Delta \phi$$

2. 反之,李代数加法 $(\phi + \Delta\phi)$ 对应的李群元素可表示为:

$$(\phi + \Delta\phi) \text{ 对应的李群} = \exp((\phi + \Delta\phi)^\wedge) = \exp((J_l \Delta\phi)^\wedge) \exp(\phi^\wedge) = \exp(\phi^\wedge) \exp((J_r \Delta\phi)^\wedge)$$

3. 同理,李群 $SE(3)$ 乘法与李代数 $\mathfrak{se}(3)$ 加法的关系:

$$\begin{aligned} \exp(\Delta\xi^\wedge) \exp(\xi^\wedge) &\approx \exp((J_l^{-1} \Delta\xi + \xi)^\wedge) \\ \exp(\xi^\wedge) \exp(\Delta\xi^\wedge) &\approx \exp((J_r^{-1} \Delta\xi + \xi)^\wedge) \end{aligned}$$

$SO(3)$ 上的李代数求导

对空间点 p 进行旋转,得到 Rp ,旋转之后点的坐标对旋转的导数可表示为:

$$\frac{\partial(Rp)}{\partial R}$$

对于上式的求导,有两种方式:

1. 用李代数 ϕ 表示**姿态** R ,然后根据李代数加法对 ϕ 求导.
2. 用李代数 φ 表示**微小扰动** ∂R ,然后根据李群左乘对 φ 求导.

其中扰动模型表达式简单,更为实用.

李代数求导

用李代数 ϕ 表示**姿态** R ,求导得到

$$\frac{\partial(Rp)}{\partial R} = \frac{\partial(\exp(\phi^\wedge)p)}{\partial \phi} = - (Rp)^\wedge J_l$$

扰动模型(左乘)

另一种求导方式是对 R 进行一次左乘扰动 ∂R ,设左乘扰动 ∂R 对应的李代数为 φ ,对 φ 求导,得到

$$\frac{\partial(Rp)}{\partial R} = \frac{\exp((\phi + \varphi)^\wedge)p - \exp(\phi^\wedge)p}{\varphi} = - (Rp)^\wedge$$


$SE(3)$ 上的李代数求导

类似地,空间点 p 经过变换 T 得到 Tp ,给 T 左乘一个扰动 $\Delta T = \exp(\delta\xi^\wedge)$,则有

$$\frac{\partial(Rp)}{\delta\xi} = \begin{bmatrix} I & -(Rp + t)^\wedge \\ 0^T & 0^T \end{bmatrix} = (TP)^\odot$$

ch05 相机与图像

针孔相机模型



$O - x - y - z$ 为相机坐标系,现实空间点 P 的**相机坐标**为 $[X, Y, Z]^T$.投影到 $O' - x' - y'$ 平面上的点 P' ,坐标为 $[X', Y', Z']^T$.

- 将成像平面对称到相机前方,根据几何相似关系 $\frac{Z}{f} = \frac{X}{X'} = \frac{Y}{Y'}$,整理得到投影点 P' 在投影平面上的坐标 $P' = [X', Y']$:

$$\begin{cases} X' = f \frac{X}{Z} \\ Y' = f \frac{Y}{Z} \end{cases}$$

- 转换得到投影点 P' 在像素平面上的**像素坐标** $P_{u,v} = [u, v]^T$

$$\begin{cases} u = \alpha X' + c_x = f_x \frac{X}{Z} + c_x \\ v = \beta Y' + c_y = f_y \frac{Y}{Z} + c_y \end{cases}$$

上式中 u, v, c_x, c_y, f_x, f_y 的单位为像素, α, β 的单位为像素/米.

- 将上式写成矩阵形式, 得到**现实空间点相机坐标 P 和投影点像素坐标 P_{uv} **之间的关系:

$$Z P_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \triangleq K P$$

其中矩阵 K 称为相机的**内参数矩阵**.


- 上式中的 P 为现实空间点在相机坐标系下的**相机坐标**, 将其转为**世界坐标** P_W , 有

$$Z P_{uv} = K(R P_W + t) = K T P_W$$

因此 R, t (或 T)又称为相机的**外参数**.

- 将最后一维进行**归一化处理**, 得到点 P 在归一化平面的**归一化坐标** $P_c = [X/Z, Y/Z, 1]^T$

$$P_c = \frac{P}{Z} = K^{-1} P_{uv}$$



参数矩阵有内参数 K 和外参数 R, t , 其中:

- 内参数矩阵 K 体现了**归一化相机坐标到像素坐标**的变换.
之所以是**归一化坐标**, 这体现了投影性质: 在某一条直线上的**空间点**, 最终会投影到同一**像素点**上.
- 外参数矩阵 R, t (或 T)体现了**世界坐标到相机坐标**的变换.

畸变模型

畸变包含两种: **径向畸变**和**切向畸变**.

- 径向畸变**: 由透镜形状引起, 主要包括**桶形畸变**和**枕形畸变**.

可以看成坐标点沿着长度方向发生了变化, 也就是其距离原点的长度发生了变化.

$$\begin{aligned} x_{distorted} &= x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y_{distorted} &= y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{aligned}$$

- **切向畸变**: 由透镜和成像平面不严格平行引起.

可以看成坐标点沿着切线方向发生了变化，也就是水平夹角发生了变化.

$$\begin{aligned}x_{distorted} &= x + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{distorted} &= y + p_1(r^2 + 2y^2) + 2p_2xy\end{aligned}$$

单目相机的成像过程

单目相机的成像过程:

1. 世界坐标系下有一个固定的原点 P ,其**世界坐标** P_W
2. 由于相机在运动,它的运动由 R, t 或变换矩阵 $T \in SE(3)$ 描述.原点 P 的**相机坐标** $\tilde{P}_c = RP_W + t$
3. 这时 \tilde{P}_c 的分量为 X, Y, Z ,把它们投影到归一化平面 $Z = 1$ 上,得到 P 的**归一化相机坐标** $P_c = \frac{\tilde{P}_c}{Z} = [\frac{X}{Z}, \frac{Y}{Z}, 1]^T$
4. 有畸变时,根据畸变参数计算 P_c 发生畸变后的归一化相机坐标
5. P 的**归一化相机坐标** P_c 经过内参 K 后,对应到它的**像素坐标** $P_{uv} = KP_c$

在讨论相机成像模型时,我们一共谈到了四种坐标: **世界坐标**、**相机坐标**、**归一化相机坐标**和**像素坐标**.请读者厘清它们的关系,它反映了整个成像的过程.

ch06 非线性优化

状态估计问题

最大后验与最大似然

SLAM模型由状态方程和运动方程构成:

$$\begin{cases} x_k = f(x_{k-1}, u_k, w_k) \\ z_{k,j} = h(y_j, x_k, v_{k,j}) \end{cases}$$

通常假设两个噪声项 $w_k, v_{k,j}$ 满足零均值的高斯分布:

$$w_k \sim \mathcal{N}(0, R_k), \quad v_{k,j} \sim \mathcal{N}(0, Q_{k,j})$$

对机器人的估计,本质上就是已知**输入数据** u 和**观测数据** z 的条件下,求机器人位姿 x 和路标点 y 的条件概率分布:

$$P(x, y | z, u)$$

利用贝叶斯法则,有:

$$P(x, y | z, u) = \frac{P(z, u | x, y)P(x, y)}{P(z, u)} \propto P(z, u | x, y)P(x, y)$$

其中 $P(x, y | z, u)$ 为**后验概率**, $P(z, u | x, y)$ 为**似然**, $P(x, y)$ 为**先验**,上式可表述为**后验概率** \propto **似然** \cdot **先验**.**直接求后验分布是困难的,但是求一个状态最优估计,使得在该状态下后验概率最大化则是可行的:**

$$(x, y)_{MAP}^* = \arg \max P(x, y | z, u) = \arg \max P(z, u | x, y)P(x, y)$$

求解**最大后验概率相当于最大化似然和先验的乘积**.因为 x, y 未知,即不知道先验,则可以求最大似然估计:

$$(x, y)_{MLE}^* = \arg \max P(z, u | x, y)$$

最大似然估计的直观意义为:**在什么样的状态下,最可能产生现在观测到的数据.**

最小二乘

基于观测数据 z 的最小二乘

对于某一次观测

$$z_{k,j} = h(y_j, x_k) + v_{k,j}$$

由于假设噪声 $v_{k,j} \sim \mathcal{N}(0, Q_{k,j})$,则观测数据 $z_{j,k}$ 的似然为

$$P(z_{j,k}|x_k,y_j) = \mathcal{N}(h(y_j,x_k),Q_{k,j})$$

将上式代入高斯分布表达式中,并取负对数,得到

$$\begin{aligned}(x_k,y_j)^* &= \arg \max \mathcal{N}(h(y_j,x_k),Q_{k,j}) \\ &= \arg \min \left((z_{k,j} - h(x_k,y_j))^T Q_{k,j}^{-1} (z_{k,j} - h(x_k,y_j)) \right)\end{aligned}$$

上式等价于最小化噪声项(即误差)的一个二次型,其中 $Q_{k,j}^{-1}$ 称为**信息矩阵**,即高斯分布协方差矩阵的逆.

基于观测数据 z 和输入数据 u 的最小二乘

因为观测 z 和输入 u 是独立的,因此可对 z 和 u 的联合似然进行因式分解:

$$P(x,y|z,u) = \prod_k P(u_k|x_{k-1},x_k) \prod_{k,j} P(z_{j,k}|x_k,y_j)$$

定义输入和观测数据与模型之间的误差:

$$\begin{aligned}e_{u,k} &= x_k - f(x_{k-1},u_k) \\ e_{z,j,k} &= z_{k,j} - h(x_k,y_j)\end{aligned}$$

定义

$$J(x,y) = \sum_k e_{u,k}^T R_k^{-1} e_{u,k} + \sum_k \sum_j e_{z,k,j}^T Q_{k,j}^{-1} e_{z,k,j}$$

则有

$$(x_k,y_j)^* = \arg \min J(x,y)$$

非线性最小二乘

对于非线性最小二乘问题:

$$\min_x F(x) = \frac{1}{2} ||f(x)||_2^2$$

求解该问题的具体步骤如下:

- 给定某个初始值 x_0
- 对于第 k 次迭代,寻找一个增量 Δx_k ,使得 $||F(x_k + \Delta x_k)||_2^2$ 达到极小值
- 若 Δx_k 足够小,则停止
- 否则,令 $x_{k+1} = x_k + \Delta x_k$,返回第2步

这样,最小二乘问题被转化为一个不断寻找下降增量 Δx_k 的问题.,具体有以下方法

一阶和二阶梯度法

将目标函数 $F(x)$ 在 x_k 附近进行泰勒展开

$$F(x_k + \Delta x_k) \approx F(x_k) + J(x_k)^T \Delta x_k + \frac{1}{2} \Delta x_k^T H(x_k) x_k$$

其中 $J(x)$ 是 $F(x)$ 关于 x 的一阶导数矩阵, $H(x)$ 是 $F(x)$ 关于 x 的二阶导数矩阵.

- 若 Δx_k 取一阶导数,则

$$\Delta x_k^* = -J(x_k)$$

- 若 Δx_k 取二阶导数,则

$$\Delta x_k^* = \arg \min \left(F(x_k) + J(x_k)^T \Delta x_k + \frac{1}{2} \Delta x_k^T H(x_k) x_k \right)$$

令上式对 Δx_k 导数等于0,则 Δx_k^* 可以取 $H \Delta x_k = -J$ 的解.

高斯牛顿法

将 $f(x_k)$ 而非 $F(x_k)$ 在 x_k 附近进行泰勒展开

$$f(x_k + \Delta x_k) \approx f(x_k) + J(x_k)^T \Delta x_k$$

则

$$\Delta x_k^* = \arg \min_{\Delta x_k} \frac{1}{2} \|f(x_k) + J(x_k)^T \Delta x_k\|^2$$

令上式对 Δx 的导数为0,得到**高斯牛顿方程**

$$J(x_k) f(x_k) + J(x_k) J^T(x_k) \Delta x_k = 0$$

令 $H(x) = J(x) J^T(x)$, $g(x) = -J(x) f(x)$, 则 Δx_k^* 可以取 $H \Delta x_k = g$ 的解.

列文伯格-马夸尔特方法

泰勒展开只能在展开点附近才有较好的近似效果,因此应给 Δx 添加一个范围,称为**信赖区域**.

定义一个指标 ρ 刻画这个近似的好坏程度,其分子为实际函数下降的值,分母是近似模型下降的值:

$$\rho = \frac{f(x + \Delta x) - f(x)}{J(x)^T \Delta x}$$

通过调整 ρ 来确定信赖区域:

- 若 ρ 接近1,则近似是最好的.
- 若 ρ 太小,说明实际下降的值远小于近似下降的值,则认为近似比较差,需要缩小近似范围.
- 若 ρ 太大,说明实际下降的比预计的更大,我们可以放大近似范围.

改良版的非线性优化框架如下:

1. 给定初始值 x_0 ,以及初始优化半径 μ
2. 对于第 k 次迭代,求解:

$$\min_{\Delta x_k} \frac{1}{2} \|f(x_k) + J(x_k)^T \Delta x_k\|^2 \quad \text{s.t.} \quad \|D \Delta x_k\|^2 \leq \mu$$

其中, μ 是信赖区域的半径, D 为系数矩阵

3. 计算 ρ
4. 若 $\rho > \frac{3}{4}$ 则 $\mu = 2\mu$
5. 若 $\rho < \frac{1}{4}$ 则 $\mu = 0.5\mu$
6. 若 ρ 大于某阈值,则认为近似可行.令 $x_{k+1} = x_k + \Delta x_k$
7. 判断算法是否收敛.如不收敛则返回第2步,否则结束.

第2步中 Δx_k 的求解要使用拉格朗日乘法:

$$\mathcal{L}(\Delta x_k, \lambda) = \frac{1}{2} \|f(x_k) + J(x_k)^T \Delta x_k\|^2 + \frac{\lambda}{2} (\|D \Delta x_k\|^2 - \mu)$$

令上式对 Δx_k 导数为0,得到

$$(H + \lambda D^T D) \Delta x_k = g$$

考虑简化形式,即 $D = I$,则相当于求解

$$(H + \lambda I)\Delta x_k = g$$

- 当 λ 较小时, H 占主要地位,这说明二次近似模型在该范围内是比较好的,列文伯格-马夸尔特方法更接近于高斯牛顿法.
- 当 λ 比较大时, λI 占据主要地位,这说明二次近似模型在该范围内不够好,列文伯格-马夸尔特方法更接近于一阶梯度下降法.

文章目录

ch02 初识SLAM

经典视觉SLAM框架

SLAM问题的数学表述

ch03 三维空间刚体运动

旋转矩阵

点和向量,坐标系

坐标系间的欧氏变换

变换矩阵与齐次坐标

齐次坐标(Homogeneous Coordinate)的优势

优势1:方便判断是否在直线或平面上

优势2:方便表示线线交点和点点共线

优势3:能够区分向量和点

优势4:能够表达无穷远点

优势5:能够简洁的表示变换

旋转向量和欧拉角

旋转向量

欧拉角

四元数

四元数的定义

用单位四元数表示旋转

ch04 李群与李代数

李群与李代数基础

群的定义

李代数的定义

李代数 $\mathfrak{so}(3)$

李代数 $\mathfrak{se}(3)$

李群与李代数的转换关系:指数映射和对数映射

$SO(3)$ 和 $\mathfrak{so}(3)$ 间的转换关系

$SE(3)$ 和 $\mathfrak{se}(3)$ 间的转换关系

李代数求导: 引入李代数的一大动机就是方便求导优化

李群乘法与李代数加法的关系

$SO(3)$ 上的李代数求导

李代数求导

扰动模型(左乘)

$SE(3)$ 上的李代数求导

ch05 相机与图像

针孔相机模型

畸变模型

单目相机的成像过程

ch06 非线性优化

状态估计问题	
最大后验与最大似然	
最小二乘	
基于观测数据 z 的最小二乘	
基于观测数据 z 和输入数据 u 的最小二乘	
非线性最小二乘	
一阶和二阶梯度法	
高斯牛顿法	
列文伯格-马夸尔特方法	
ch07 视觉里程计01	
特征点匹配	
特征点	
根据特征点匹配计算相机运动	
2D-2D匹配: 对极几何	
对极约束	
本质矩阵 E 的求解	
对极几何的讨论	
3D-2D匹配: PnP(Perspective-n-Point)	
直接线性变换(DLT): 先求解相机位姿,再求解空间点位置	
P3P: 先求解空间点位置,再求解相机位姿	
Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿	
3D-3D匹配: ICP	
SVD方法	
非线性优化方法	

ch07 视觉里程计01

特征点匹配

特征点

根据特征点匹配计算相机运动

根据特征点匹配计算相机运动.根据相机的成像原理不同,分为以下3种情况:

1. 当相机为单目时,我们只知道匹配点的像素坐标,是为2D-2D匹配,使用对极几何求解.
2. 当相机为双目或RGB-D时,我们就知道匹配点的像素坐标和深度坐标,是为3D-3D匹配,使用ICP求解.
3. 如果有3D点及其在相机的投影位置,也能估计相机的运动,是为3D-2D匹配,使用PnP求解.

2D-2D匹配: 对极几何

对极约束

[外链图片转存失败,源站可能有防盗链机制,建议将图片保存下来直接上传(img-QVwt5bIH-1587570602884)(1587436458419.png)][:height="50%" width="50%"]

假设我们要求取两帧图像 I_1, I_2 之间的运动,设第一帧到第二帧的运动为 R, t ,两个相机中心分别为 O_1, O_2 .考虑 I_1 中有一个特征点 p_1 ,它在 I_2 中对应着特征点 p_2 .连线 $\overrightarrow{O_1 p_1}$ 和 $\overrightarrow{O_2 p_2}$ 在三维空间中交于点 P ,这时点 O_1, O_2, P 三个点可以确定一个平面,称为**极平面**. $O_1 O_2$ 连线与像平面 I_1, I_2 的交点分别为 e_1, e_2 . e_1, e_2 称为极点, $O_1 O_2$ 称为基线,极平面与两个像平面 I_1, I_2 之间的相交线 l_1, l_2 称为极线.

P 在 I_1 下的相机坐标为 $P = [X, Y, Z]^T$,两个投影像素点 p_1, p_2 的像素位置为 $s_1 p_1 = K P, s_2 p_2 = K(RP + t)$.

取 p_1, p_2 的归一化坐标 $x_1 = K^{-1} p_1, x_1 = K^{-1} p_2$,则可以推得 $x_2 \simeq R x_1 + t$.上式中 \simeq 表示尺度意义上相等,即在齐次坐标下是相等的,物理上表示对原点成投影关系.

经过推导,得到:

$$x_2^T t^\wedge R x_1 = 0 \tag{1}$$

代入 p_1, p_2 ,得到:

$$p_2^T K^{-T} t^\wedge R K^{-1} p_1 \tag{2}$$

式(1)和式(2)都称为对极约束,定义基础矩阵 F 和本质矩阵 E ,可以进一步简化对极约束:

$$E = t^\wedge R \quad F = K^{-T} E K^{-1} \quad x_2^T E x_1 = p_2^T F p_1 = 0 \tag{3}$$

由于 E 与 F 之间只差了相机内参,相机内参是已知的,因此实践中往往使用形式更简单的 E .

本质矩阵 E 的求解

考虑到 E 的尺度等价性,可以用8对点来估计 E ,是为八点法.

对于一对匹配点,其归一化坐标 $x_1 = [u_1, v_1, 1]^T, x_2 = [u_2, v_2, 1]^T$.根据对极约束,有

$$(u_1, v_1, 1) \begin{pmatrix} e_1 & e_2 & e_3 \\ e_4 & e_5 & e_6 \\ e_7 & e_8 & e_9 \end{pmatrix} \begin{pmatrix} u_2 \\ v_2 \\ 1 \end{pmatrix} = 0$$

把矩阵 E 展开为向量 $e = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^T$,对极约束可以写成与 e 有关的线性形式:

$$[u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_2, u_2, v_2, 1] \cdot e = 0$$

把八对点对应的 x_1, x_2 分别代入方程中,得到线性方程组:

$$\begin{pmatrix} u_1^1 u_2^1 & u_1^1 v_2^1 & u_1^1 & v_1^1 u_2^1 & v_1^1 v_2^1 & v_2^1 & u_2^1 & v_2^1 & 1 \\ u_1^2 u_2^2 & u_1^2 v_2^2 & u_1^2 & v_1^2 u_2^2 & v_1^2 v_2^2 & v_2^2 & u_2^2 & v_2^2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_1^8 u_2^8 & u_1^8 v_2^8 & u_1^8 & v_1^8 u_2^8 & v_1^8 v_2^8 & v_2^8 & u_2^8 & v_2^8 & 1 \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \\ e_6 \\ e_7 \\ e_8 \\ e_9 \end{pmatrix} = 0$$

求得E后,对 E 进行SVD分解以求取 R, t .设 E 的SVD分解为 $E = U \Sigma V^T$,则对应的 R, t 分别为:

$$t^\wedge = U R_Z(\frac{\pi}{2}) \Sigma U^T \quad R = U R_Z^T(\frac{\pi}{2}) \Sigma U^T$$

其中 $R_Z(\frac{\pi}{2})$ 表示沿 Z 轴旋转90°得到的旋转矩阵.

对极几何的讨论

1. 尺度不确定性: 2D图像不具有深度信息,这导致了**单目视觉的尺度不确定性**.

实践中设 t 为单位1,计算相机运动和和特征点的3D位置,这被称为单目SLAM的**初始化**.

2. 初始化的纯旋转问题: 若相机发生纯旋转,导致 t 为零,得到的 E 也将为零,会导致我们无从求解R.因此**单目初始化不能只有纯旋转,必须要有一定程度的平移**.

3. 多于8对点的情况:

对于八点法,有 $Ae = 0$,其中 A 为一个8×9的矩阵.

若匹配点的个数多于8个, A 的尺寸变化,上述方程不成立.因此转而求取最小化二次型

$$\min_e ||Ae||_2^2 = \min_e e^T A^T A e$$

是为最小二乘意义下的 E 矩阵.

3D-2D匹配: PnP(Perspective-n-Point)

2D-2D的对极几何方法需要8个或8个以上的点对（以八点法为例），且存在着初始化、纯旋转和尺度的问题。然而，如果两张图像中其中一张特征点的3D位置已知，那么最少只需3个点对（需要至少一个额外点验证结果）就可以估计相机运动。

在双目或RGB-D的视觉里程计中，我们可以直接使用PnP估计相机运动。而在单目视觉里程计中，必须先进行初始化，然后才能使用PnP。

PnP问题有多种解决方法:

1. 直接线性表变换(DLT): 先求解相机位姿,再求解空间点位置
2. P3P: 先求解空间点位置,再求解相机位姿
3. Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿

直接线性变换(DLT): 先求解相机位姿,再求解空间点位置

考虑某个空间点 P 的齐次世界坐标为 $P = (X, Y, Z, 1)^T$.在图像 I_1 中投影到特征点的归一化像素坐标 $x_1 = (u_1, v_1, 1)^T$.此时相机的位姿 R, t 是未知的,定义增广矩阵 $[R|t]$ (不同于变换矩阵 T)为一个 3×4 的矩阵,包含了旋转与平移信息,展开形式如下:

$$s \begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \begin{pmatrix} t_1 & t_2 & t_3 & t_4 \\ t_5 & t_6 & t_7 & t_8 \\ t_9 & t_{10} & t_{11} & t_{12} \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix}$$

用最后一行把 s 消去,得到两个约束:

$$\begin{cases} \mathbf{t}_1^T P - \mathbf{t}_3^T P u_1 = 0 \\ \mathbf{t}_2^T P - \mathbf{t}_3^T P v_1 = 0 \end{cases}$$

其中 $\mathbf{t}_1 = (t_1, t_2, t_3, t_4)^T, \mathbf{t}_2 = (t_5, t_6, t_7, t_8)^T, \mathbf{t}_3 = (t_9, t_{10}, t_{11}, t_{12})^T$. $\mathbf{t}_1, \mathbf{t}_2, \mathbf{t}_3$ 为待求量.

将 N 对匹配的特征点代入方程中,得到线性方程组:

$$\begin{pmatrix} P_1^T & 0 & -u_1 P_1^T \\ 0 & P_1^T & -v_1 P_1^T \\ \vdots & \vdots & \vdots \\ P_N^T & 0 & -u_N P_N^T \\ 0 & P_N^T & -v_N P_N^T \end{pmatrix} \begin{pmatrix} \mathbf{t}_1 \\ \mathbf{t}_2 \\ \mathbf{t}_3 \end{pmatrix} = 0$$

只需6对匹配点即可求解增广矩阵 $[R|t]$,若匹配点数多于6对时,可以求最小二乘解.对于求解出的旋转矩阵 R ,可以通过QR分解等手段将其投影到 $SE(3)$ 上.

P3P: 先求解空间点位置,再求解相机位姿

[外链图片转存失败,源站可能有防盗链机制,建议将图片保存下来直接上传(img-9luduXXH-1587570602886)(1587451327097.png)]

已知3对匹配点的世界坐标 A, B, C 和投影坐标 a, b, c ,根据三角形的余弦定理,有

$$\begin{cases} OA^2 + OB^2 - 2OA \cdot OB \cdot \cos\langle a, b \rangle = AB^2 \\ OB^2 + OC^2 - 2OB \cdot OC \cdot \cos\langle b, c \rangle = BC^2 \\ OA^2 + OC^2 - 2OA \cdot OC \cdot \cos\langle a, c \rangle = AC^2 \end{cases}$$

记 $x = OA/OC, y = OB/OC, u = BC^2/AB^2, v = AC^2/AB^2$

$$\begin{cases} (1-u)y^2 - ux^2 - \cos\langle b, c \rangle y + 2uxy \cos\langle a, b \rangle + 1 = 0 \\ (1-w)x^2 - wy^2 - \cos\langle a, c \rangle y + 2wxy \cos\langle a, b \rangle + 1 = 0 \end{cases}$$

上式中,三个余弦角 $\cos\langle a, b \rangle, \cos\langle b, c \rangle, \cos\langle a, c \rangle$ 以及 u, v 是已知的,可以求解出 x, y ,进而求解出 A, B, C 三点的相机坐标.然后根据3D-3D的点对,计算相机的运动 R, t .

Bundle Adjustment: 最小化重投影误差,同时求解空间点位置和相机位姿

设相机位姿变换矩阵 T ,某空间点的世界坐标 $P_i = [X_i, Y_i, Z_i]^T$,其投影的像素坐标为 $\mathbf{u}_i = [u_i, v_i]^T$,像素位置与空间点位置的关系如下:

$$s_i \mathbf{u}_i = K T P_i$$

由于相机位姿未知及观测点的噪声,上式存在一个误差,称为**重投影误差** $e = u_i - \frac{1}{s_i} K T P_i$.因此我们对重投影误差求和,寻找最好的相机位姿和特征点的空间位置,最小化重投影误差:

$$T^* = \arg \min_T \frac{1}{2} \sum_{i=1}^n \|u_i - \frac{1}{s_i} K T P_i\|^2$$

$$P_i^* = \arg \min_{P_i} \frac{1}{2} \sum_{i=1}^n \|u_i - \frac{1}{s_i} K T P_i\|^2$$

使用最小二乘优化,要分别求 e 对 T 和 P 的导数:

$$e(x + \Delta x) \approx e(x) + J \Delta x$$

- 求 e 对 T 的导数:

当 e 为像素坐标误差(2维), x 为相机位姿(6维)时, J 将是一个 2×6 的矩阵.我们来推导 J 的形式:

$$\text{取中间变量 } P' = (TP)_{1:3} = [X', Y', Z']^T$$

使用李代数求导的扰动模型,对 T 左乘微小扰动 $\delta\xi$,求得得到:

$$\frac{\partial e}{\partial \delta\xi} = \lim_{\delta\xi \rightarrow 0} \frac{e(\delta\xi \oplus \xi) - e(\xi)}{\delta\xi} = \frac{\partial e}{\partial P'} \frac{\partial P'}{\partial \delta\xi}$$

其中的 \oplus 表示李代数的左乘扰动

其中第一项 $\frac{\partial e}{\partial P'}$:

$$\frac{\partial e}{\partial P'} = - \begin{bmatrix} \frac{\partial u}{\partial X'} & \frac{\partial u}{\partial Y'} & \frac{\partial u}{\partial Z'} \\ \frac{\partial v}{\partial X'} & \frac{\partial v}{\partial Y'} & \frac{\partial v}{\partial Z'} \end{bmatrix} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix}$$

第二项 $\frac{\partial P'}{\partial \delta\xi}$ 为变换后的点关于李代数的导数:

$$\frac{\partial P'}{\partial \delta\xi} = \frac{(TP)}{\partial \delta\xi} = (TP)^\odot = \begin{bmatrix} I & -P'^\wedge \\ 0^T & 0^T \end{bmatrix}$$

在 P' 定义中,取出前三维,得到

$$\frac{\partial P'}{\partial \delta\xi} = [I, -P'^\wedge]$$

将两项相乘,得到了 2×6 的雅可比矩阵 J^T

$$J^T = \frac{\partial e}{\partial \delta\xi} = - \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X'^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{bmatrix}$$

- 求 e 对 P 的导数

3D-3D匹配: ICP

对于一组已配对好的3D点:

$$P = \{p_1, \dots, p_n\}, \quad P' = \{p'_1, \dots, p'_n\}$$

现在,想要找一个欧氏变换 R, t ,使得:

$$\forall i, \quad p_i = R p'_i + t$$

ICP问题的求解包含两种方式:

1. 利用线性代数的求解(主要是SVD)
2. 利用非线性优化方式的求解(类似于Bundle Adjustment)

SVD方法

定义第*i*对点的误差项为 $e_i = p_i - (Rp'_i + t)$,定义两组点的质心 $p = \frac{1}{n} \sum_{i=1}^n (p_i), p' = \frac{1}{n} \sum_{i=1}^n (p'_i)$

构建最小二乘问题,求取最合适的 R, t .

$$\begin{aligned} \min_{R,t} J &= \frac{1}{2} \sum_{i=1}^n ||(p_i - (Rp'_i + t))||_2^2 \\ &= \frac{1}{2} \sum_{i=1}^n ||p_i - p - R(p'_i - p')||^2 + ||p - Rp' - t||^2 \end{aligned}$$

左边只和旋转矩阵 R 相关,而右边既有 R 也有 t ,但只和质心相关.因此令左边取最小值解出 R ,代入到右边令式子等于0求出 t .

定义去质心坐标 $q_i = p_i - p, q'_i = p'_i - p'$,则优化目标可写成:

$$\begin{aligned} R^* &= \min_R \sum_{i=1}^n ||p_i - p - R(p'_i - p')||^2 \\ &= \min_R \sum_{i=1}^n -q_i^T R q'_i \\ &= -tr \left(R \sum_{i=1}^n q'_i q_i^T \right) \end{aligned}$$

省略数学证明,定义矩阵:

$$W = \sum_{i=1}^n q_i q_i'^T$$

对矩阵 W 进行SVD分解得到:

$$W = U \Sigma V^T$$

可求解

$$R = UV^T$$

非线性优化方法

使用李代数表达表达位姿,目标函数可以写成

$$\min_{\xi} = \frac{1}{2} \sum_{i=1}^n ||(p_i - \exp(\xi^\wedge) p'_i)||_2^2$$

误差项关于位姿的导数可以用李代数求导的扰动模型,计算导数得到:

$$\frac{\partial e}{\partial \delta \xi} = -(\exp(\xi^\wedge) p'_i)^\odot$$

可以直接使用最小二乘优化方法求解位姿.

相关推荐