

视觉SLAM十四讲|第10讲 后端1

10 人赞同了该文章

咸鱼了好久。。。起来接着学习。

上来就又被先验后验搞蒙了，重新理解一下：

先验概率：根据以往经验和分析得到的概率，它往往作为“由因求果”问题中的“因”出现。

后验概率：指在得到“结果”的信息后重新修正的概率，是“执果寻因”问题中的“因”。

最大的区别就在于结果/当前观测在后验概率中已知，在先验概率中未知。

1. 后端要做什么？

前端能够根据相邻的两幅图像判断出此时此刻的位姿，是暂时的；那么后端需要对前端测量以及计算的结果进行矫正，不仅用过去的信息，也用未来的信息更新自己，希望能够得到一个长时间的正确状态。

前面有讲过，在运动方程和观测方程中，如果把位姿和路标看成随机变量，就可以把问题变为已知观测数据和运动数据情况下，如何确定状态量的分布问题，是一个状态估计问题。假设噪声和状态量服从高斯分布，只需要估计它的均值和方差，即可确定状态量的分布。

完成后端优化可以使用滤波器，也可以使用非线性优化，本讲对两种方法都做了推导。

2. 滤波器推导

先做一些符号的定义和铺垫：

把位姿和路标写在一起，记为： $\mathbf{x}_k \triangleq \{\mathbf{x}_k, \mathbf{y}_1, \dots, \mathbf{y}_m\}$ ，用新符号写运动方程和观测方程，为：

$$\begin{cases} \mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{u}_k) + \mathbf{w}_k \\ \mathbf{z}_k = \mathbf{h}(\mathbf{x}_k) + \mathbf{v}_k \end{cases} \quad k = 1, \dots, N。$$

需要求解的是后验概率问题，即在已知0时刻的状态、1:k时刻的观测下，k时刻的状态分布，写为 $P(\mathbf{x}_k | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k})$ ，根据贝叶斯法则，将后验概率展开为似然和先验概率的乘积，写为 $P(\mathbf{x}_k | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k}) \propto P(\mathbf{z}_k | \mathbf{x}_k) P(\mathbf{x}_k | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1})$ 。

先验概率中k时刻的状态 \mathbf{x}_k 受到前面0:k-1时刻状态的影响，对先验概率进行展开，可以写为

$$P(\mathbf{x}_k | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = \int P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) P(\mathbf{x}_{k-1} | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) d\mathbf{x}_{k-1}$$

，在进行滤波器模型推导时，假设马尔可夫性（k时刻状态只与k-1时刻状态有关，与之前状态无关）。可以根据马尔可夫性对先验概率的展开式进行化简，积分中第一个概率化简为



$P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k)$, 第二个概率化简为

$P(\mathbf{x}_{k-1} | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_{k-1} | \mathbf{x}_0, \mathbf{u}_{1:k-1}, \mathbf{z}_{1:k-1})$ (运动方程中k时刻状态只受到k-1时刻的状态和k时刻的运动数据相关)。

2.1 卡尔曼滤波器 (线性高斯系统)

在线性高斯系统中, 用线性方程描述运动方程和观测方程, 写为

$$\begin{cases} \mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{u}_k + \mathbf{w}_k \\ \mathbf{z}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{v}_k \end{cases} \quad k = 1, \dots, N, \text{ 记噪声服从零均值高斯分布:}$$

$$\mathbf{w}_k \sim N(\mathbf{0}, \mathbf{R}), \quad \mathbf{v}_k \sim N(\mathbf{0}, \mathbf{Q}), \text{ 令 } \hat{\mathbf{x}}_k \text{ 表示后验, } \bar{\mathbf{x}} \text{ 表示先验。}$$

因为各随机变量服从高斯分布, 误差服从零均值高斯分布, 根据高斯分布的特性 (后面解释) 和观测方程、运动方程, 可以分别写出似然和先验的分布:

$$P(\mathbf{x}_k | \mathbf{x}_0, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = N(\mathbf{A}_k \hat{\mathbf{x}}_{k-1} + \mathbf{u}_k, \mathbf{A}_k \hat{\mathbf{P}}_{k-1} \mathbf{A}_k^T + \mathbf{R})$$

$$P(\mathbf{z}_k | \mathbf{x}_k) = N(\mathbf{C}_k \mathbf{x}_k, \mathbf{Q})$$

把先验均值和方差记为 $\bar{\mathbf{x}}_k = \mathbf{A}_k \hat{\mathbf{x}}_{k-1} + \mathbf{u}_k, \quad \bar{\mathbf{P}}_k = \mathbf{A}_k \hat{\mathbf{P}}_{k-1} \mathbf{A}_k^T + \mathbf{R}$

根据后验、似然、先验的关系, 有: $N(\hat{\mathbf{x}}_k, \hat{\mathbf{P}}_k) = N(\mathbf{C}_k \mathbf{x}_k, \mathbf{Q}) \cdot N(\bar{\mathbf{x}}_k, \bar{\mathbf{P}}_k)$

高斯分布底数为e, 比较等式两边的指数项 (不考虑常数项) 有,

$$(\mathbf{x}_k - \hat{\mathbf{x}}_k)^T \hat{\mathbf{P}}_k^{-1} (\mathbf{x}_k - \hat{\mathbf{x}}_k) = (\mathbf{z}_k - \mathbf{C}_k \mathbf{x}_k)^T \mathbf{Q}^{-1} (\mathbf{z}_k - \mathbf{C}_k \mathbf{x}_k) + (\mathbf{x}_k - \bar{\mathbf{x}}_k)^T \bar{\mathbf{P}}_k^{-1} (\mathbf{x}_k - \bar{\mathbf{x}}_k)$$

比较两边的系数, 经过一系列推导可以得到后验均值和方差的表达式。

整个卡尔曼滤波的过程为:



1. 预测:

$$\bar{\mathbf{x}}_k = \mathbf{A}_k \hat{\mathbf{x}}_{k-1} + \mathbf{u}_k, \quad \bar{\mathbf{P}}_k = \mathbf{A}_k \hat{\mathbf{P}}_{k-1} \mathbf{A}_k^T + \mathbf{R}. \quad (10.24)$$

2. 更新: 先计算 \mathbf{K} , 它又称为卡尔曼增益:

$$\mathbf{K} = \bar{\mathbf{P}}_k \mathbf{C}_k^T (\mathbf{C}_k \bar{\mathbf{P}}_k \mathbf{C}_k^T + \mathbf{Q})^{-1}. \quad (10.25)$$

然后计算后验概率的分布:

$$\begin{aligned} \hat{\mathbf{x}}_k &= \bar{\mathbf{x}}_k + \mathbf{K} (z_k - \mathbf{C}_k \bar{\mathbf{x}}_k) \\ \hat{\mathbf{P}}_k &= (\mathbf{I} - \mathbf{K} \mathbf{C}_k) \bar{\mathbf{P}}_k. \end{aligned} \quad (10.26)$$

知乎 @笨丫头

在第一步预测中, 使用k-1时刻的后验分布估计k时刻的先验分布, 这一步不确定性变大, 第二步使用k时刻的先验分布估计k时刻的后验分布, 对于结果进行修正, 缩小不确定性。

2.2 拓展卡尔曼滤波器EKF (非线性系统)

将线性系统拓展到非线性系统, 通常会在某个点处对方程进行展开, 保留一阶项, 按照线性系统进行推导。

对于k时刻的运动方程, 展开有:

$$\begin{aligned} \mathbf{x}_k &\approx f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_k) + \left. \frac{\partial f}{\partial \mathbf{x}_{k-1}} \right|_{\hat{\mathbf{x}}_{k-1}} (\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + \mathbf{w}_k, \text{ 记偏导数为} \\ \mathbf{F} &= \left. \frac{\partial f}{\partial \mathbf{x}_{k-1}} \right|_{\hat{\mathbf{x}}_{k-1}}. \end{aligned}$$

对于k时刻的观测方程, 展开有: $z_k \approx h(\bar{\mathbf{x}}_k) + \left. \frac{\partial h}{\partial \mathbf{x}_k} \right|_{\bar{\mathbf{x}}_k} (\mathbf{x}_k - \bar{\mathbf{x}}_k) + \mathbf{n}_k$, 记偏导数为

$$\mathbf{H} = \left. \frac{\partial h}{\partial \mathbf{x}_k} \right|_{\bar{\mathbf{x}}_k}.$$

利用和线性系统类似的方法, 推导得到预测步骤 (没看明白怎么推的, 如有大神请帮忙解释一下): $\bar{\mathbf{x}}_k = f(\hat{\mathbf{x}}_{k-1}, \mathbf{u}_k)$, $\bar{\mathbf{P}}_k = \mathbf{F} \hat{\mathbf{P}}_{k-1} \mathbf{F}^T + \mathbf{R}_k$

卡尔曼增益: $\mathbf{K}_k = \bar{\mathbf{P}}_k \mathbf{H}^T (\mathbf{H} \bar{\mathbf{P}}_k \mathbf{H}^T + \mathbf{Q}_k)^{-1}$

更新步骤: $\hat{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{K}_k (z_k - h(\bar{\mathbf{x}}_k))$, $\hat{\mathbf{P}}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \bar{\mathbf{P}}_k$

EKF的局限性：马尔可夫假设、一次线性化，这两个数学上的处理化简了问题，但是偏离了实际情况。记录均值、方差、路标等信息，存储量大。



3. 非线性优化（BA与图优化）

Bundle Adjustment，是指从视觉重建中提炼出最优的3D模型和相机参数（内参数和外参数）。

3.1 优化目标

回顾整个投影过程，假设已知相机的外参数（R, t）和世界坐标系的p点坐标，求解p点的像素坐标过程。

世界坐标转化为相机坐标： $\mathbf{P}' = \mathbf{R}\mathbf{p} + \mathbf{t} = [X', Y', Z']^T$

相机坐标投影到归一化平面： $\mathbf{P}_c = [u_c, v_c, 1]^T = [X'/Z', Y'/Z', 1]^T$

去畸变（径向畸变）：
$$\begin{cases} u'_c = u_c (1 + k_1 r_c^2 + k_2 r_c^4) \\ v'_c = v_c (1 + k_1 r_c^2 + k_2 r_c^4) \end{cases}$$

计算像素坐标：
$$\begin{cases} u_s = f_x u'_c + c_x \\ v_s = f_y v'_c + c_y \end{cases}$$

整个过程中，用到了相机的位姿（R, t）和路标p的世界坐标，得到了路标的像素坐标，对应到观测方程 $z=h(x,y)$ 中，观测z就是像素坐标 $[u_s, v_s]^T$ ，相机位姿x用李代数表示 ξ ，路标y用三维点p的坐标。那么通过降低观测到的像素坐标z和估计到的像素坐标 $h(\xi, p)$ 之间的误差，就可以得到最优的x和y的解。用最小二乘表示整体的代价函数为：

$$\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n \|e_{ij}\|^2 = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n \|z_{ij} - h(\xi_i, p_j)\|^2$$

采用非线性优化更新增量的方式求解，令 $\mathbf{x} = [\xi_1, \dots, \xi_m, p_1, \dots, p_n]^T$ ， $f(\mathbf{x}) = z_{ij} - h(\xi_i, p_j)$ 。

引入增量后，目标函数变为：

$$\frac{1}{2} \|f(\mathbf{x} + \Delta\mathbf{x})\|^2 \approx \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n \|e_{ij} + \mathbf{F}_{ij}\Delta\xi_i + \mathbf{E}_{ij}\Delta p_j\|^2$$

\mathbf{F}_{ij} 表示 $f(x)$ 对于相机位姿的偏导数， \mathbf{E}_{ij} 表示 $f(x)$ 对于路标点位置的偏导数。

接下来使用第六章的非线性优化方法进行求解，在求解时不免要计算 $H\Delta x = g$ ，利用H矩阵的稀疏性能够加速求解。

3.2 稀疏性

在高斯牛顿法中 $H = J^T J$ ，在列文伯格——马夸尔特方法中 $H = J^T J + \lambda I$ ，所以H的稀疏性主要是由J引起的。

对于代价函数中的 e_{ij} ，描述的是在 ξ_i 看到 p_j ，只与这两个量相关，所以

$$J_{ij}(x) = \left(\mathbf{0}_{2 \times 6}, \dots, \mathbf{0}_{2 \times 6}, \frac{\partial e_{ij}}{\partial \xi_i}, \mathbf{0}_{2 \times 6}, \dots, \mathbf{0}_{2 \times 3}, \dots, \mathbf{0}_{2 \times 3}, \frac{\partial e_{ij}}{\partial p_j}, \mathbf{0}_{2 \times 3}, \dots, \mathbf{0}_{2 \times 3} \right)$$

由于 $H = J^T J$ ，J只在i和j处有非零块，所以矩阵H中只有(i,i),(i,j),(j,i),(j,j)处有非零块，其中i是相机部分，j是路标部分。

举例说明，假设有2个相机位姿 (C_1, C_2) 和6个路标 $(P_1, P_2, P_3, P_4, P_5, P_6)$ ，那么相机所对应的变量有 $\xi_i, i = 1, 2$ ，路标对应变量有 $p_j, j = 1, \dots, 6$ 。如图10-4所示，连线表示相机可以看到路标。




图 10-4 点和边组成的示意图。该图显示相机 C_1 观测到了路标点 P_1, P_2, P_3, P_4 ，相机 C_2 看到了 P_3 到 P_6 。

图10-4的场景，用目标函数表示应该是：

$$\frac{1}{2} \left(\|e_{11}\|^2 + \|e_{12}\|^2 + \|e_{13}\|^2 + \|e_{14}\|^2 + \|e_{23}\|^2 + \|e_{24}\|^2 + \|e_{25}\|^2 + \|e_{26}\|^2 \right)$$

其中 e_{11} 描述的是相机 C_1 观测到了 p_1 ，把所有变量按照 $x = (\xi_1, \xi_2, p_1, \dots, p_2)^T$ 的顺序摆放，则雅各比矩阵为

$$J_{11} = \frac{\partial e_{11}}{\partial \xi_1} = \left(\frac{\partial e_{11}}{\partial \xi_1}, \mathbf{0}_{2 \times 6}, \frac{\partial e_{11}}{\partial p_1}, \mathbf{0}_{2 \times 3}, \mathbf{0}_{2 \times 3}, \mathbf{0}_{2 \times 3}, \mathbf{0}_{2 \times 3}, \mathbf{0}_{2 \times 3} \right)$$

依次类推可以得到目标函数每一项的雅各比矩阵，叠放在一起，用方块表示非零块，则矩阵J和H的非零值如图10-6所示。




图 10-6 Jacobian 矩阵的稀疏性 (左) 和 H 矩阵的稀疏性 (右), 蓝色的方块表示矩阵在对应的矩阵块处有数值, 其余没有颜色的部分表示矩阵在该处的数值始终为 0。

每个非零块都对应着相机和路标点的关系, 拓展开来, 可以把 H 矩阵划分成四个区域, 如图 10-9 所示。




图 10-9 H 矩阵的区域划分。

其中 BC 是对角块矩阵, B 的对角块与相机位姿的维度相同, C 的对角块与路标维度相同, E 的数值和具体的观测相关。

3.3 边缘化 (Marginalization)

把相机位姿变量放到一起, 记为 $\mathbf{x}_c = [\xi_1, \xi_2, \dots, \xi_m]^T \in \mathbb{R}^{6m}$, 把空间点的变量放在一起, 记为 $\mathbf{x}_p = [p_1, p_2, \dots, p_n]^T \in \mathbb{R}^{3n}$ 。

在非线性优化中, 需要根据 $H\Delta\mathbf{x} = \mathbf{g}$ 求解增量, 用分块矩阵表示 H 后变为:

$$\begin{bmatrix} \mathbf{B} & \mathbf{E} \\ \mathbf{E}^T & \mathbf{C} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{x}_c \\ \Delta\mathbf{x}_p \end{bmatrix} = \begin{bmatrix} \mathbf{v} \\ \mathbf{w} \end{bmatrix}, \text{ 需要想办法计算两个增量。}$$

先消去右上角的 E :
$$\begin{bmatrix} \mathbf{I} & -\mathbf{EC}^{-1} \\ 0 & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{B} & \mathbf{E} \\ \mathbf{E}^T & \mathbf{C} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{x}_c \\ \Delta\mathbf{x}_p \end{bmatrix} = \begin{bmatrix} \mathbf{I} & -\mathbf{EC}^{-1} \\ 0 & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{v} \\ \mathbf{w} \end{bmatrix},$$

整理得到 [公式],

用第一行计算出 $\Delta\mathbf{x}_c$ 的值, 再带入第二行, 求解 $\Delta\mathbf{x}_p$, 这个过程称为 Marginalization。

3.4 鲁棒核函数



当输入的数据存在无匹配时，误差会很大，在二范式中产生的梯度也会很大，从而导致增量朝着错误的方向变化。选用一个具有光滑性质并且变化较小的函数可以使得系统更稳健，这种函数称为鲁棒核函数，比如Huber核：

$$H(e) = \begin{cases} \frac{1}{2}e^2 & \text{if } |e| \leq \delta \\ \delta(|e| - \frac{1}{2}\delta) & \text{otherwise} \end{cases}。$$

附录A.3

高斯函数性质：

对于随机变量 $\mathbf{x} \sim N(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$ ，若有 $\mathbf{y} = \mathbf{Ax} + \mathbf{b} + \mathbf{w}$ ，其中A, b为线性变量的稀疏矩阵核偏移量，w为噪声项，且 $\mathbf{w} \sim N(\mathbf{0}, \mathbf{R})$ ，有

$$p(\mathbf{y}) = N(\mathbf{A}\boldsymbol{\mu}_x + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}_{xx}\mathbf{A}^T + \mathbf{R})。$$

参考文献

[1] 《视觉SLAM十四讲从理论到实践》 高翔，张涛